

Dynamique de frappe

Malo MARTIN

Février 2026

Table des matières

Introduction	1
0.1 Définitions et choix.	2
1 Analyse en composantes principales.	3
2 Clustering.	7
2.1 Méthode ascendante	7
2.2 Méthode K-mean	11
2.3 Conclusion sur les classifications non supervisées	13
3 Analyse discriminante.	13
3.1 Analyse discriminante linéaire	14
4 Conclusion	17
5 Bibliographie	19

Introduction

Dans cette étude, nous nous intéressons à un jeu de données portant sur la dynamique de frappe d'un même mot de passe (à savoir **tie5Roanl**) par différents individus.

Plus précisément, 51 sujets ont saisi chacun le mot de passe **tie5Roanl** à 376 reprises. La base de données se présente sous la forme d'un tableau, où chaque ligne contient différentes informations (**variables**) relatives à une entrée du mot de passe par un sujet. Chaque ligne commence par le numéro du sujet ayant saisi le mot de passe, suivi du temps en secondes pendant lequel le sujet appuie sur chacune des touches composant le mot de passe, ainsi que du temps nécessaire pour passer d'une touche à la suivante.

L'objectif de cette étude est de déterminer si des individus peuvent être différenciés (ou classifiés), grâce à leur cadence de frappe lors de la saisie d'un mot de passe, en utilisant des méthodes de classification statistique implémentées en Python. Une application concrète de cette étude serait de pouvoir établir, de

manière fiable si, en cas de vol d'un mot de passe, il est possible de distinguer, à partir de la cadence de frappe d'un individu lors de la saisie de ce mot de passe, si celui-ci est le détenteur originel du mot de passe ou un usurpateur.

0.1 Définitions et choix.

En statistique, une ligne d'une base de données est habituellement appelée un individu. Pour éviter toute confusion, nous désignerons par saisie une ligne du tableau, c'est-à-dire l'ensemble des informations relatives à une saisie particulière du mot de passe par un individu particulier. Une saisie est donc composée :

- d'une variable qualitative indiquant le numéro du sujet
- de 21 variables quantitatives mesurant, en secondes, la cadence de frappe lors de cette saisie.

La variable sujet constitue ainsi la variable de classification, compte tenu du problème traité.

Les différentes méthodes de classification statistique des données ont été mises en œuvre dans le langage Python, à l'aide du logiciel Jupyter Notebook, sur un ordinateur portable peu puissant. Pour des raisons de performance, le nombre de saisies par sujet a été réduit de moitié, en sélectionnant aléatoirement 188 saisies par sujet (soit $376/2$). Aussi, pour rendre les résultats interprétables et exploitables, le nombre de sujets observés a été restreint à 4, sélectionnés aléatoirement parmi les 51. En effet, l'analyse simultanée des 51 sujets entraîne une superposition des cadences de frappe, rendant les sujets difficilement séparables. De plus, les graphiques deviennent illisibles avec un nombre aussi élevé de classes.

Cette étude est divisée en deux grandes parties : la première partie explore la possibilité de classer quatre sujets en fonction de leur cadence de frappe.

La deuxième partie aborde quant à elle la question de la prédiction, en fonction de la cadence de frappe, de l'identité de l'auteur de la saisie parmi quatre sujets.

Le choix de se limiter à quatre individus, sélectionnés aléatoirement parmi les 51 disponibles dans le jeu de données, est justifié par l'objectif final de cette étude : déterminer s'il est possible d'identifier un individu par rapport à d'autres, sur la base de sa cadence de frappe habituelle lors de la saisie de son mot de passe.

Il ne s'agit pas ici d'évaluer si la cadence de frappe d'une séquence de caractères donnée peut constituer une méthode d'authentification fiable, comparable à une empreinte digitale. L'enjeu est plutôt de vérifier, dans un premier temps, si les cadences de frappe de ces quatre individus permettent de les distinguer les uns des autres. Cela permettra de juger s'il est raisonnable d'envisager, dans

un deuxième temps, la prédiction de l'identité d'un individu parmi trois autres, en fonction d'une cadence de frappe.

1 Analyse en composantes principales.

Une fois nos données réduites à 188 saisies du mot de passe par 4 sujets différents, nous obtenons un tableau de 752 lignes (soit 188×4), chacune représentant une saisie, et de 22 colonnes correspondant aux variables. Nous pouvons ensuite extraire de ce tableau la variable qualitative associée au numéro du sujet ayant saisi le mot de passe, comme suit pour l'exemple des sujets 11, 27, 31 et 55 :

Sujet	H.period	UD.period.t	...	H.return
11	0.0863	0.1155	...	0.14
11	0.0855	0.0868	...	0.1428
11	0.0689	0.0944	...	0.1761
...	...	...	...	...
55	0.0997	0.0429	...	0.0955
55	0.0966	0.0316	...	0.1282

$\longrightarrow (Y, X)$

Avec $Y = \begin{pmatrix} 11 \\ 11 \\ . \\ . \\ 55 \end{pmatrix} \in \mathbb{R}^{752}$, le vecteur de la variable de classe des sujets.

Et $X = \begin{pmatrix} 0.0863 & \dots & 0.14 \\ 0.0855 & \dots & 0.1428 \\ \dots & \dots & \dots \\ \dots & \dots & \dots \\ 0.0966 & \dots & 0.1282 \end{pmatrix} \in \mathbb{R}^{752 \times 21}$, la matrice des variables quantitatives.

Ainsi, les variables quantitatives d'une saisie peuvent être assimilées à un vecteur de $\mathbb{R}^{21}$, ce qui rend nos données manipulables mathématiquement, mais visuellement irreprésentables dans leur espace d'origine. Plusieurs raisons motivent la nécessité de réduire la dimension de ces données :

- Avec 21 variables, il est impossible de visualiser directement les données dans un espace à deux ou trois dimensions, ce qui empêche une interprétation intuitive des résultats.

- Le grand nombre de variables entraîne un coût élevé pour les méthodes statistiques (en termes de temps de calcul et de ressources), ainsi qu'un risque d'erreurs d'approximation qui augmente.
- Certaines variables sont liées entre elles. Par exemple, le temps total de saisie du mot de passe peut être obtenu par la somme des temps de frappe de chaque touche. Ces dépendances linéaires rendent certaines variables redondantes, ce qui peut biaiser les analyses statistiques.

Toutes ses remarques mènent à penser qu'il est souhaitable de résumer l'information contenu dans les variables. Pour cela, on fait appelle à l'analyse en composantes principales, ou **ACP**.

L'ACP est une méthode statistique d'analyse qui permet de réduire la dimension des données en projetant les variables originelles sur un nouvel espace de dimensions inférieures (les composantes principales), tout en maximisant la variance expliquée (la dispersion des saisies). Dans ce nouvel espace, les composantes principales sont orthogonales entre elles, ce qui élimine les problèmes de multicollinéarité.

L'ACP est ici adaptée car elle permet de simplifier l'analyse tout en préservant l'information essentiel pour la classification des individus. Elle servira de pré-traitement avant l'application d'autres méthodes de classification (comme les k-mean et la CAH), en réduisant le bruit et en améliorant la séparabilité des classes.

Avant de réaliser l'Analyse en Composantes Principales (ACP) sur la matrice X , il est important de standardiser les variables. En effet, bien que toutes les variables de X soient exprimées en secondes, certaines peuvent prendre une importance artificielle en raison d'effets d'échelle. Par exemple, deux touches du clavier peuvent être plus éloignées l'une de l'autre que d'autres paires, ce qui augmente le temps de transition entre elles. Cette variation, peut biaiser l'ACP en accordant un poids excessif à ces variables, sans que cela reflète leur réelle importance pour la classification. Pour éviter ces biais, nous appliquons une standardisation à chaque variable de X :

Centrage : On soustrait la moyenne de chaque variable pour éliminer les effets de translation.

Réduction : On divise chaque variable centrée par son écart-type, afin de leur attribuer une variance unitaire.

Cette transformation de X en une nouvelle matrice X_s garantit que toutes les variables contribuent équitablement à l'ACP, indépendamment de leur échelle initiale.

On réécrit à présent la matrice X_s selon les composante principal C_i et les axes principaux v_i , obtenus par la décomposition en valeurs singulières de X_s :

$$X_s = \sum_{i=1}^{21} C_i v_i^T, \text{ avec } \|C_1\| \geq \|C_2\| \geq \dots \geq \|C_{21}\|.$$


On définit l'inertie des saisies : $I = \frac{1}{n} \sum_{i=1}^{21} \|X_i\|^2$. Or, les variables sont centrées, cette quantité correspond à la somme des variances des saisies et mesure donc leur dispersion. On définit de la même façon l'inertie des saisies sur l'espace des k premières composantes principales de X_s , noté I_k . On obtient alors le rapport d'inertie expliquée E_k :

$$E_k = \frac{I_k}{I} = \frac{\|C_1\|^2 + \|C_2\|^2 + \dots + \|C_k\|^2}{\|C_1\|^2 + \|C_2\|^2 + \dots + \|C_{21}\|^2}.$$

Ainsi, pour un coefficient E_k assez proche de 1, on pourra raisonnablement faire l'approximation : $X_s \simeq \sum_{i=1}^k C_i v_i^T$.

Dans le cadre de notre étude, pour les sujets 12, 13, 22 et 31, l'application de la méthode `linalg.svd()` en Python permet d'obtenir un taux d'inertie cumulé $E_2 = 0.663$ pour les deux premières composantes principales (avec $E_1 = 0.533$). Cela signifie que près des deux tiers de l'information totale contenue dans les 21 variables initiales sont conservés grâce à ces deux composantes seulement.

Aussi, il devient possible de représenter les saisies dans le plan (C_1, C_2) , ce qui permet d'évaluer visuellement la séparabilité des sujets :




La figure de gauche représente les saisies standardisées. On observe que les sujets y sont bien séparés malgré la réduction à seulement deux composantes principales. Cette séparation est encourageante et justifie la poursuite de l'étude, car elle suggère que la cadence de frappe contient des informations discriminantes exploitables.

Quant à la figure de droite, elle illustre les saisies non standardisées. Dans ce cas, le taux d'inertie cumulé atteint $E_2 \simeq 0.8$, ce qui indique que l'ACP conserve une plus grande part de la variabilité des données. Pourtant, les sujets y sont moins distincts, ce qui confirme un phénomène important : en l'absence de standardisation, l'ACP tend à concentrer l'information dans des composantes influencées par des variables de grande échelle, sans que celles-ci soient nécessairement pertinentes pour la séparabilité des individus.

Cette comparaison appuie sur l'importance de la standardisation pour garantir que l'ACP reflète les différences significatives entre les sujets, plutôt que les différences d'échelles des variables.

On peut à partir de là tracer le cercle de corrélation (projection des variables d'origine sur le plan (C_1, C_2)), pour étudier le lien entre les variables d'origines et les deux premières composantes principales :



On observe que les variables sont bien représentées dans le plan factoriel, leur norme étant proche du cercle de corrélation. Cela indique que leur projection sur les deux premières composantes principales est fidèle à leur structure originelle.

Par ailleurs, deux groupes de variables se distinguent clairement. Les variables H. (temps de pression sur les touches) sont fortement corrélées entre elles et se situent d'un même côté de l'axe C_1 . Les variables UD. (temps de transition entre les touches) sont également fortement corrélées entre elles, mais se trouvent du côté opposé de l'axe C_1 .

La composante C_1 sépare ainsi les variables de pression des variables de transition. Cette opposition reflète une relation inverse entre ces deux types de mesures : un temps de pression prolongé sur une touche semble impliquer un temps de transition réduit vers la touche suivante, et réciproquement.

Cela peut s'expliquer par un effet mécanique et visuel : plus un utilisateur maintient une touche enfoncée (par exemple pour s'assurer de son appui), plus il a le temps d'anticiper le mouvement vers la touche suivante, ce qui accélère la transition. À l'inverse, une pression rapide peut entraîner une recherche visuelle ou motrice plus longue pour la touche suivante, augmentant ainsi le temps de transition. Cette dépendance entre temps de pression et temps de transition contenue dans C_1 , suggère que la cadence de frappe est dirigée par un équilibre

entre ces deux phases, la variabilité de cet équilibre entre les sujets pourrait permettre leur classification.

2 Clustering.

Maintenant que les données ont été réduites et concentrées grâce à l'ACP, nous allons procéder à une classification non supervisée. L'objectif est de regrouper les saisies en classes, en fonction de leur proximité dans l'espace des composantes principales, puis d'évaluer si cette classification coïncide avec celle basée sur les sujets (c'est-à-dire sur l'identité réelle des individus).

2.1 Méthode ascendante

On va dans un premier temps utiliser la méthode de classification ascendante hiérarchique (notée **CAH**), dont la première étape consiste à définir une mesure de dissimilarité entre deux saisies. Étant donné que les variables de la matrice X_s (obtenue après ACP) sont toutes numériques, l'outil qui s'impose pour cette tâche est une mesure de distance.

Nous dirons que deux saisies x et y (deux lignes distinctes de X_s) sont proches si, pour une norme donnée $\|\cdot\|$, la distance $d(x, y) = \|xy\|$ est faible par rapport aux distances entre x ou y et les autres saisies de X_s . Autrement dit, la proximité est évaluée relativement aux distances entre les saisies.

Remarque : Cette analyse souligne l'importance de la standardisation. En effet, les différences d'échelles entre les variables peuvent biaiser l'évaluation des distances entre deux saisies, en donnant un poids excessif aux variables dont l'échelle est la plus grande. Ainsi, sans standardisation, la distance entre deux saisies pourrait être dominée par les variables de plus grande amplitude, masquant les différences subtiles mais significatives sur les autres variables.

En revanche, le centrage (une étape de la standardisation) n'a pas d'impact sur le calcul des distances, car celles-ci sont invariantes par translation.

Pour former des groupes de saisies, il est nécessaire de mesurer les distances entre ensembles de points. Nous utilisons pour cela la distance de Ward, notée d_W , définie par :

$$d_W(A, B) = \frac{|A| \cdot |B|}{|A| + |B|} \|g_A - g_B\|^2 \quad (1)$$

Avec g_A , g_B les centres de gravité des groupes de saisies A et B, et $|\cdot|$ l'effectif d'un groupe.

La distance de Ward mesure ainsi la distance entre les centres de gravité des nuages de points. Elle est adaptée à notre contexte, car elle permet de comparer des groupes contenant un grand nombre de saisies. De plus, on montre facilement que le carré de la distance de Ward entre deux classes correspond à la variance

inter-classes, ce qui en fait une mesure pertinente pour évaluer la séparation entre groupes.

On peut à présent appliquer la CAH sur nos données de la façon suivante :

- 1 : Initialiser avec une classe par individu.
- 2 : Fusionner les deux classes les plus proches selon la distance de Ward.
- 3 : Revenir à (2) jusqu'à fusion complète.
- 4 : Chaque étape donne une classification.

On peut tirer de cette méthode un arbre détaillant chaque fusion.

La CAH est un outil d'analyse. Pour dégager une structuration pertinente des données, il est important de déterminer à partir de quel seuil de distance la méthode commence à fusionner des classes trop dissemblables.


Application de la CAH sur deux groupes de quatre sujets

Dans le cadre de notre étude, une ACP appliquée aux variables standardisées X_s issues des saisies des sujets 16, 21, 25 et 55, permet d'obtenir un taux d'inertie cumulé $E_5 = 0.631$ pour les cinq premières composantes principales. Ce résultat est inférieur à celui obtenu pour les sujets 17, 22, 27 et 48, pour lesquels $E_5 = 0.761$. Dans la suite, on note X_{acp} la matrice constituée des cinq vecteurs colonnes $C_1, C_2, \dots, C_5$ obtenus par ACP sur la matrice standardisée X_s , issue des variables de saisie X .

Après application de la CAH, en utilisant la méthode *linkage()* de la bibliothèque *scipy* en Python, nous analysons les données réduites X_{acp} issues des sujets 16, 21, 25 et 55. Cette méthode génère un tableau des distances interclasses (calculées selon le critère de Ward), qui reflètent les distances entre les groupes à chaque étape de fusion. Les distances de fusion observées lors des dernières itérations de la CAH sont les suivantes :

...9.79 10.44 10.57 11.3 11.49 12.03 12.49 14.51 14.84 17.49 18.33 18.37
19.71 22.55 28.87 31.18 38.56 61.03 78.68]

Les distances de fusion augmentent progressivement à chaque étape, ce qui est cohérent avec le fonctionnement de l'algorithme. Cependant, on observe des bonds significatifs dans les distances successives lors des trois dernières étapes. Ces bonds indiquent que les fusions réalisées à ce stade concernent des classes très distinctes, comparativement aux regroupements précédents. Avant ces trois dernières fusions, l'algorithme avait formé quatre classes distinctes de saisies. Cette structuration en quatre groupes est donc pertinente, car elle correspond à une séparation naturelle des données. Ainsi, en fixant un seuil de distance de fusion à 35, nous respectons la structuration des saisies en quatre classes suggérée par la CAH. Cela permet de tracer l'arbre hiérarchique suivant :



Dans cet arbre, les quatre couleurs correspondent aux quatre classes identifiées par la CAH. Les abscisses représentent les distances de fusion entre les classes, tandis que les ordonnées indiquent les saisies.

Nous pouvons désormais vérifier si la classification des saisies proposée par la CAH coïncide avec la classification par sujet. Pour ce faire, nous récupérons les numéros de sujet (contenus dans Y) associés à chaque saisie au sein de chaque classe. En identifiant le sujet majoritaire dans chaque classe, nous calculons un taux d'erreur d'attribution pour chaque classe, défini comme suit :

$$\text{Taux d'erreur} = \frac{\text{Nombre de saisies d'un sujet} - \text{Nombre de saisies majoritaires dans la classe}}{\text{Nombre de saisies d'un sujet}}$$

$$\text{Taux de saisies mal classées} = \frac{\text{nombre de saisies mal classées}}{\text{nombre total de saisies}}$$

===== Analyse : CAH =====

Classe 1 → Sujet majoritaire : 16 (182 sur 188), taux d'erreur : 0.032

Classe 2 → Sujet majoritaire : 55 (126 sur 188), taux d'erreur : 0.33


Classe 3 → Sujet majoritaire : 25 (178 sur 188), taux d'erreur : 0.053

Classe 4 → Sujet majoritaire : 21 (171 sur 188), taux d'erreur : 0.09

Taux de mal classés : 0.126

Bien que le taux global de mal classés (0.126) soit relativement élevé, il est fortement influencé par les erreurs d'attribution dans la Classe 2, où le sujet 55 présente un taux d'erreur de 0.33. Ce résultat peut s'expliquer par le fait que le nombre de saisies correctement attribuées au sujet 55 est inférieur à celui des autres sujets dans leur classe respective. Certaines saisies du sujet 55 se

superposent avec celles des autres sujets, ce qui rend leur classification plus difficile. Pour vérifier cette hypothèse, on regarde la matrice de confusion associée à cette CAH, afin de visualiser les confusions entre sujets, ainsi que le graphique de projection des données X_s sur le plan formé par les deux premiers axes de l'ACP, pour observer la répartition spatiale des saisies et identifier d'éventuels chevauchements entre les sujets.



La lecture de la matrice de confusion révèle que la Classe 2 n'est pas composée exclusivement de saisies du sujet 55. En effet, une partie de ses saisies a été classée par la CAH dans la Classe 4, où le sujet 21 est majoritaire. Cela suggère que les saisies du sujet 55 se superposent partiellement avec celles du sujet 21, ce que l'on peut confirmer visuellement en examinant le graphique de projection situé à droite de la matrice.

Pour le second groupe de sujets (17, 22, 27 et 48), les distances de fusion observées lors des dernières itérations de la CAH sont les suivantes :

... 1.293e+01 1.676e+01 1.678e+01 1.740e+01 2.398e+01 3.153e+01
4.546e+01 6.971e+01 1.060e+02]

On constate que la CAH fusionne à nouveau des classes nettement distinctes lors des trois dernières itérations, comme en témoignent les bonds importants dans les distances de fusion. En conséquence, nous choisissons cette fois un seuil de distance de fusion de 30, en nous basant sur ces résultats. Les taux d'erreur d'attribution obtenus pour chaque classe sont alors les suivants :

===== Analyse : CAH =====

Classe 1 → Sujet majoritaire : 48 (188 individus), taux d'erreur : 0.0

Classe 2 → Sujet majoritaire : 27 (188 individus), taux d'erreur : 0.0


Classe 3 → Sujet majoritaire : 17 (186 individus), taux d'erreur : 0.011

Classe 4 → Sujet majoritaire : 22 (188 individus), taux d'erreur : 0.0
Taux de mal classés : 0.003

Le taux d'erreur global a considérablement diminué (0.003) par rapport à l'exemple précédent (0.126). Cette amélioration peut s'expliquer par deux facteurs principaux :

Une ACP plus fidèle aux données d'origine, avec un taux d'inertie cumulé de 0.73 (contre 0.63 précédemment).

Une moins grande superposition des variables de saisie entre les sujets, comme le confirme le graphique de projection des nouvelles données X_s sur le plan formé par les deux premiers axes de l'ACP.



En somme, la classification hiérarchique ascendante montre que les sujets peuvent être séparés en fonction de leur dynamique de frappe. Cependant, cette méthode présente des limites, notamment lorsque des saisies appartenant à des sujets différents se superposent.

2.2 Méthode K-mean

Bien que les résultats obtenus avec la CAH soient encourageants, ils ne permettent pas d'affirmer avec certitude que l'on peut identifier de manière fiable des sujets à partir de leur dynamique de frappe, en raison d'un taux d'erreur de classification trop élevé dans certains cas. Nous allons donc nous orienter vers une nouvelle méthode de classification : la méthode des k-means.

Dans le cadre de la méthode des k-means, la proximité des saisies est déterminée en fonction de leur distance à un centre (ou centroïde). En principe on choisit un nombre fixe de centres (ici, $k = 4$, car nous savons que nous avons quatre sujets distincts), et pour chaque saisie, on associe le centroïde le plus proche, ce qui permet de former les classes.

Cette méthode de classification est particulièrement adaptée à notre problème, car nous connaissons à l'avance le nombre de groupes attendus (quatre sujets). Ce nombre de groupes est cohérent avec les résultats obtenus par la CAH, qui a suggéré une structuration en quatre classes.

Nous cherchons à déterminer les centres $c_1, c_2, \dots, c_k$ qui minimisent la somme des distances entre chaque donnée x et le centre le plus proche. Cela se formalise par l'équation suivante :


$$\sum_x \min_{j=1, \dots, n} \|x - c_j\|^2 \quad (2)$$

Dans notre cas, x représente une saisie standardisée après ACP, c'est-à-dire une ligne de la matrice X_{acp} (où seules les 5 premières composantes principales sont conservées). Le nombre de centres k est fixé à 4, correspondant aux quatre sujets étudiés.

La méthode de classification par k-means s'effectue de la façon suivante :

- 1 : Partir de n centres tirés aléatoirement.
- 2 : Associer à chaque donnée son centre le plus proche.
- 3 : Recalculer chaque centre comme moyenne des données qui lui ont été associées.
- 4 : Revenir à (2), jusqu'à convergence.

On implémente cette méthode sur nos données issues des saisies des sujets 16, 21, 25 et 55 à l'aide du module *k-means* de la bibliothèque *sklearn.cluster*. On obtient alors la matrice de confusion suivante :



On observe immédiatement une nette amélioration de la classification grâce à la méthode des k-means, en particulier pour le sujet 25, qui est désormais beaucoup mieux identifié, comme en témoignent les taux d'erreur par classe :

===== Analyse : K-means =====

Classe 0 → Sujet majoritaire : 55 (169 individus), taux d'erreur : 0.101
 Classe 1 → Sujet majoritaire : 25 (185 individus), taux d'erreur : 0.016
 Classe 2 → Sujet majoritaire : 16 (167 individus), taux d'erreur : 0.112
 Classe 3 → Sujet majoritaire : 21 (172 individus), taux d'erreur : 0.085
 Taux de mal classés : 0.078

2.3 Conclusion sur les classifications non supervisées

On peut conclure que la méthode des k-means offre une classification plus précise que la CAH dans notre étude. Plusieurs raisons expliquent cette supériorité :

- Connaissance a priori du nombre de classes : la méthode des k-means est utilisée pour nombre de classes connu (quatre sujets). Elle optimise donc directement une classification en quatre groupes, contrairement à la CAH, qui construit une hiérarchie de groupes par fusion successive et nécessite un choix de seuil de distance de fusion pour déterminer le nombre final de classes.
- Minimisation de l'inertie intra-classe : les k-means minimisent explicitement l'inertie intra-classe (la dispersion des saisies au sein d'une même classe), comme le montre l'équation (2).

Cette approche favorise la formation de groupes compacts, adaptés à la structure des données, comme le confirment les graphiques de projection sur les deux premières composantes principales. En revanche, la CAH minimise l'inertie inter-classe à chaque fusion, selon la formule (1). Cette méthode est davantage adaptée à des données dont les classes seraient plus éloignées les unes des autres.

Les résultats de la classification par CAH ont permis de montrer que les saisies sont globalement structurées en quatre groupes, correspondant assez bien aux quatre sujets. Ce résultat a justifié l'utilisation des k-means avec quatre centres, ce qui a amélioré significativement les performances de la classification. La question de savoir si il est possible de prédire l'identité d'un sujet en fonction de sa cadence de frappe se pose donc naturellement.

3 Analyse discriminante.

Comme cela a été détaillé dans la partie 1, nos données sont structurées en deux composantes :

Une variable qualitative de classe Y , représentant l'identité du sujet. Des variables quantitatives X , décrivant la cadence de frappe. Ainsi, la i -ème saisie dans le jeu de données (X, Y) correspond à la i -ème ligne de cette matrice. Elle peut être décomposée en une paire (Y_i, X_i) , où Y_i désigne le numéro de l'un des quatre sujets (tirés aléatoirement) et $X_i \in \mathbb{R}^{21}$ représente les 21 variables quantitatives décrivant la cadence de frappe de cette saisie.

Notre objectif est désormais de prédire Y_i en fonction de X_i , c'est-à-dire de déterminer, à partir de la cadence de frappe d'une saisie, quel est son auteur parmi les quatre sujets.

Plus précisément, si l'on considère les paires (Y_i, X_i) comme des réalisations indépendantes et identiquement distribuées (i.i.d.) d'une loi conjointe $P_{X,Y}$ (où X et Y sont des variables aléatoires générales), on choisira y comme la valeur la plus vraisemblable sachant x . Ce qui peut s'exprimer mathématiquement d'après

la règle bayésienne :

$$\hat{y} = \arg \max_y P_{Y|X}(y|X = x) = \arg \max_y \frac{P_{Y,X}(y|X = x)}{P_X(x)} = \arg \max_y P_{Y,X}(y|X = x) \quad (3)$$

Ici, $\hat{y}$ représente une estimation du numéro du sujet en fonction de la cadence de frappe x d'une saisie donnée.

3.1 Analyse discriminante linéaire

L'utilisation de la formule (3) nécessite de faire des hypothèses sur les lois de probabilités qui y interviennent.

Ainsi, en notant ns_1, ns_2, ns_3, ns_4 les numéros des sujets étudiés, on considère que Y_i suit la loi discrète telle que : $P(Y_i = ns_j) = p_j$, pour $j = 1, \dots, 4$.

Pour chaque sujet ns_j , la variable X_i (représentant la cadence de frappe) suit une loi normale multidimensionnelle : $(X_i|Y_i = ns_j) \sim \mathcal{N}(\mu_j, W)$, où μ_j est la cadence de frappe moyenne du sujet ns_j , et W est la matrice de variance covariance commune à tous les sujets.

On obtient alors la loi conjointe :

$$p_{X,Y}(x, ns_j) = p_{X|Y}(x|ns_j)p_j = g_{\mu_j, W}(x)p_j \quad (4)$$

Avec $g_{\mu_j, W}$ la densité de $N(\mu_j, W)$.

Remarque : Nous avons notamment supposé que la matrice de variance covariance W de la loi normale multidimensionnelle de X sachant Y est indépendante de la valeur prise par Y . Cette hypothèse, appelée hypothèse d'homoscédasticité, est caractéristique de l'Analyse Discriminante Linéaire (LDA) et la distingue d'autres méthodes discriminantes (comme l'Analyse Discriminante Quadratique, QDA).

Les paramètres p_j , μ_j et W intervenant dans la formule (4) ne sont pas connus a priori, mais peuvent être estimés à partir des données de notre problème :

- $\hat{p}_j = \frac{188}{4 \times 188} = \frac{1}{4}$, la probabilité de tirer le numéro ns_j .
- $\hat{\mu}_j = \frac{1}{188} \sum_{i: Y_i = ns_j} X_i$, moyenne des X_i observés pour lesquels $Y_i = ns_j$.
- $\hat{R}_j = \frac{1}{188} \sum_{i: Y_i = ns_j} (X_i - \hat{\mu}_j)(X_i - \hat{\mu}_j)^T$, variance observée dans la classe ns_j .
- $\hat{W} = \frac{1}{4} \sum_{j=1}^4 \hat{R}_j$, variance interclasse (d'après l'hypothèse d'homoscédasticité).

Ainsi, pour une nouvelle saisie X_i dont le numéro de sujet est inconnu, nous estimons ce numéro $\hat{y}$ en utilisant la règle de décision (3). En substituant les estimateurs aux paramètres inconnus, nous obtenons :


$$\begin{aligned}\hat{y} &= \arg \max_{ns_j} g_{\hat{\mu}_j, \hat{W}}(X_i) \hat{p}_j \quad (5) \\ &= \arg \max_{ns_j} (X^T \hat{W}^{-1} \hat{\mu}_j - \frac{1}{2} \hat{\mu}_j^T \hat{W}^{-1} \hat{\mu}_j - \ln(\hat{p}_j))\end{aligned} \quad (1)$$

Cette expression montre que la décision de la valeur de $\hat{y}$ dépend linéairement de X_i , ce qui justifie le nom d'Analyse Discriminante Linéaire (LDA). Une conséquence importante est que toute transformation linéaire de X_i (comme une standardisation) n'affecte pas la valeur de $\hat{y}$, rendant cette étape inutile dans le cadre de la LDA, contrairement à ce que nous faisons pour l'ACP.

En revanche, comme pour l'ACP, l'Analyse Discriminante Linéaire (LDA) permet une réduction de la dimensionnalité du problème en identifiant de nouvelles composantes, dont le nombre est strictement inférieur au nombre de classes. Dans notre cas, avec 4 sujets, les données contenues dans X peuvent être projetées sur trois composantes après application de la LDA.

Nous pouvons désormais déterminer la valeur la plus vraisemblable de y pour une donnée X_i . Cette méthode a été implémentée en Python à l'aide du module *LinearDiscriminantAnalysis* de la bibliothèque *sklearn.discriminant_analysis*. Pour cette analyse, nous avons choisi de conserver uniquement deux composantes.

Pour les variables de cadence de frappe X issues des sujets 4, 39, 54 et 55, nous obtenons une variable prédite $\hat{Y}$, qui estime le numéro du sujet auquel appartient chaque cadence de frappe (chaque ligne X_i de X). Nous pouvons comparer cette variable prédite $\hat{Y}$ avec la variable réelle Y en examinant la matrice de confusion :




Le taux d'erreur de prédiction est :

$$\frac{\text{nombre de numeros sujet mal predits}}{\text{nombre total de saisies}} = 0.021.$$


Ce taux d'erreur est nettement inférieur à ceux obtenus avec les méthodes de classification précédentes. En effet, pour les sujets 4, 39, 54 et 55, après une ACP sur les données standardisées et en conservant cinq composantes principales (contre deux pour la LDA), nous obtenons un taux d'erreur de classification de 0.145 avec la méthode CAH, et un taux d'erreur de classification de 0.064 avec la méthode des k-means.

Cette amélioration peut s'expliquer par la différence de variance expliquée par les composantes issues de l'ACP et celles issues de la LDA, comme le montre la comparaison entre ces deux histogrammes :



La variance expliquée par les cinq premières composantes issues de l'ACP sur les variables standardisées X_s est de 56,85%, tandis qu'elle atteint 82,52% pour les deux premières composantes issues de la LDA sur X . Ainsi, les deux premières composantes obtenues par LDA reflètent bien mieux la variabilité des données que celles issues de l'ACP.


Conjointement, cette meilleure adéquation aux données permet également une meilleure séparation des saisies en fonction du sujet qui en est l'auteur. Cela est visible en comparant la projection des données standardisées X_s sur les deux premières composantes principales issues de l'ACP et la projection des données X sur les deux premières composantes issues de la LDA :



Ce qui indique que les sujets sont mieux séparés par leur cadence de frappe que ne le suggèrerait l'ACP, et que la LDA permet de mieux rendre compte de cette partition des données par sujet.

Bien que la LDA obtienne un taux d'erreur de prédiction très faible (2,1%) et bien inférieur à ceux des méthodes CAH (14,5%) et k-means (6,4%), cette performance doit être relativisée. En effet, le modèle prédictif de la LDA a été entraîné sur l'ensemble des données X , ce qui ne permet pas de garantir sa généralisation à de nouvelles saisies. Pour évaluer la robustesse du modèle, il est nécessaire de le tester sur des données inconnues.

Pour ce faire, nous utilisons la méthode de validation croisée 5-fold, qui consiste à partitionner les données X en cinq groupes, chacun représentant 20% des données, puis entraîner le modèle prédictif de la LDA sur quatre de ces groupes. Ensuite il faut tester le modèle sur le cinquième groupe (groupe de test), et itérer en changeant le groupe de test et le groupe d'entraînement, de manière à couvrir l'intégralité des données, comme illustré dans le schéma suivant :



Cette approche permet d'obtenir une validation croisée des résultats de prédiction, réduisant ainsi l'impact de la variabilité des données due à un agencement particulier de celles-ci. Elle teste également l'ensemble des données, ce qui permet de tirer des conclusions plus robustes.

En implémentant cette méthode en Python à l'aide du module *cross_val_predict* de la bibliothèque *sklearn.model_selection*, toujours pour les saisies des sujets 4, 39, 54 et 55, nous obtenons un taux d'erreur de 2,9%. Ce résultat, bien que légèrement supérieur à celui obtenu sans validation croisée, reste relativement bas et confirme une bonne capacité de prédiction des numéros de sujet en fonction des cadences de frappe.

4 Conclusion

Notre étude, menée sur les saisies de quatre sujets tirés aléatoirement parmi 51, a permis d'établir progressivement plusieurs résultats.

Tout d'abord, grâce à une Analyse en Composantes Principales (ACP) appliquée aux données standardisées, nous avons montré que les dynamiques de

frappe étaient partiellement séparées par sujet.

Les méthodes de classification CAH puis *k-means* ont ensuite permis de quantifier cette séparation, révélant que les données étaient bien structurées en quatre groupes, correspondant aux quatre sujets étudiés. Cette analyse a motivé la recherche de la prédiction du numéro du sujet en fonction d'une cadence de frappe.

Enfin, la LDA (Analyse Discriminante Linéaire) a été appliquée en ne conservant que les deux premières composantes, ce qui a permis de réduire drastiquement la dimensionnalité du problème tout en concentrant une grande partie de la variabilité des données sur un nombre réduit de composantes, comparé à l'ACP. La projection des données sur ces deux composantes a révélé une meilleure séparation des sujets que celle observée avec les composantes principales de l'ACP.

Les résultats de la LDA ont montrés une très bonne prédiction pour les numéros de sujet 4, 39, 54 et 55 (2.1% d'erreur d'attribution de numéros), mais ce taux peut descendre à 1.7% pour les sujets 13,28,33 et 41, ou monter à 8% pour les sujets 4,15,17 et 50. Dans tous les cas, ces résultats restent satisfaisants et confirment que la dynamique de frappe permet de discriminer efficacement les individus.

Cependant, si l'on souhaite établir un protocole fiable pour détecter l'utilisation d'un mot de passe par des usurpateurs, cette étude seule ne suffit pas à motiver le développement d'un tel projet. En effet, tout au long de cette analyse, nous avions connaissance du nombre de sujets (quatre dans notre cas). Cette information a certes permis de vérifier que les sujets étaient bien séparés par leur dynamique de frappe dans la partie dédiée à la classification, mais si toutefois on veut se rapprocher d'un scénario plus réaliste d'usurpation, il serait nécessaire de compléter l'analyse discriminante en testant la prédiction dans une configuration différente de la variable de numéro de sujet, afin de mieux refléter les conditions d'une tentative d'usurpation.

Par exemple, on pourrait sélectionner aléatoirement un sujet parmi les 51 et le désigner comme le propriétaire légitime du mot de passe, puis considérer les 50 autres sujets comme des usurpateurs potentiels.

Dans ce cadre, il n'y aurait plus que deux classes (propriétaire et usurpateurs), ce qui simplifie l'interprétation des résultats tout en maintenant la lisibilité des graphiques. L'objectif serait alors d'évaluer, après application de la LDA, si le taux d'erreur d'attribution (confusion entre le propriétaire et les usurpateurs) est suffisamment faible pour envisager la mise en place d'un protocole efficace de détection d'usurpation.

Cette approche permettrait de valider la faisabilité d'un système d'authentification basé sur la dynamique de frappe, dans un contexte plus proche de la réalité.

5 Bibliographie

- https://foad.univ-rennes.fr/pluginfile.php/1281830/mod_resource/content/8/AnaDiscr_trs.pdf
- <https://www.datacamp.com/fr/tutorial/k-fold-cross-validation>
- https://foad.univ-rennes.fr/pluginfile.php/1281829/mod_resource/content/14/Cluster_trs.pdf
- https://foad.univ-rennes.fr/pluginfile.php/1281828/mod_resource/content/27/ACP_trs.pdf
- <https://towardsdatascience.com/linear-discriminant-analysis-lda-598d8e90f8b9/>